

Controle de um Robô com Linguagem Natural usando LBML e Aprendizado de Máquina

Guilherme Rosa¹

¹Programa de Pós-Graduação em Computação Aplicada – UDESC
Joinville, SC – Brasil

`guilherme.mr@udesc.br`

Abstract. *Este trabalho apresenta um sistema para controlar o robô LBot por meio de comandos em linguagem natural. A solução utiliza a linguagem de domínio específico LBML e um modelo de aprendizado de máquina para traduzir comandos em português.*

Resumo. *O artigo descreve um sistema que permite controlar o robô LBot usando comandos em linguagem natural. A abordagem emprega a linguagem LBML e um modelo de aprendizado de máquina para traduzir comandos em português, com avaliação de desempenho por métricas de tradução automática.*

1. Introdução

Atualmente, dois campos que despertam grande interesse tanto na academia quanto na indústria são a Robótica e a Inteligência Artificial. O avanço nessas áreas tem proporcionado impactos significativos na sociedade, permitindo a criação de soluções inovadoras que já fazem parte do cotidiano.

O projeto apresentado neste artigo integra os campos de Robótica e Inteligência Artificial. Para isso, foi desenvolvido o robô LBot, cuja principal funcionalidade é a movimentação no espaço físico. A fim de possibilitar que esses movimentos sejam descritos de forma padronizada, foi criada uma linguagem de domínio específico (DSL), denominada LBot Movement Language (LBML).

Entretanto, um desafio recorrente em aplicações de robótica é a necessidade de que o usuário aprenda comandos técnicos ou linguagens específicas para interagir com o robô. Para contornar esse problema, este trabalho propõe o uso de um modelo de aprendizado de máquina capaz de traduzir comandos em português para a LBML, permitindo que usuários interajam com o LBot por meio de linguagem natural.

Diante desse contexto, este artigo apresenta a criação da LBML, o desenvolvimento do conjunto de dados de treinamento e a implementação de um modelo baseado em arquiteturas de transformers utilizando a biblioteca PyTorch, permitindo a tradução de comandos em português para a LBML. A combinação de linguagens de domínio e aprendizado de máquina demonstra como a interação entre humanos e robôs pode ser simplificada. Além disso, a utilização de comandos em linguagem natural torna o LBot mais acessível a usuários sem conhecimento técnico, potencializando aplicações práticas em educação, entretenimento e pesquisa em robótica.

2. Revisão de Conceitos e Trabalhos Relacionados

A interface entre a linguagem natural e as máquinas é um campo de pesquisa fundamental para a Robótica e a Inteligência Artificial (IA), sendo o núcleo deste trabalho o problema de Semantic Parsing (Análise Semântica). Esta seção explora os conceitos centrais e os trabalhos de ponta que pavimentaram o caminho para a tradução eficiente de comandos em linguagem natural para linguagens formais e de domínio específico.

2.1. Semantic Parsing e Linguagens de Domínio Específico (DSL)

O Semantic Parsing é a tarefa de traduzir frases em linguagem natural (LN) em representações formais e executáveis, como código de programação, expressões lógicas ou queries de banco de dados (Sharma et al. 2025). Embora o foco tradicional recaia sobre a conversão de perguntas para Structured Query Language (SQL) (o chamado NL-to-SQL), o conceito se estende a qualquer linguagem de máquina que defina ações em um domínio restrito, como é o caso do LBot.

A escolha de uma Linguagem de Domínio Específico (DSL), como a proposta LBML, em vez de uma linguagem de propósito geral, tem se mostrado crucial para aumentar a precisão e a interpretabilidade. A DSL restringe o vocabulário e a sintaxe a comandos específicos de movimento, eliminando a ambiguidade inerente à linguagem humana.

Trabalhos recentes têm enfatizado que o uso de uma DSL como intermediário melhora a confiabilidade dos sistemas. A abordagem mediada por DSL (DSL-Mediated Approach), por exemplo, é defendida para evitar a alucinação e a redundância geradas por modelos de linguagem grandes (LLMs) ao traduzir diretamente para linguagens de propósito geral (Wu et al. 2025). Este estudo, focado em estratégias financeiras, demonstrou que a conversão em duas etapas (LN $\rightarrow$ DSL $\rightarrow$ Linguagem de Programação) alcança uma alta taxa de correspondência exata, reforçando o valor da DSL como uma barreira de segurança.

Esta filosofia é implementada diretamente na LBML. Quando o usuário expressa a intenção em português ("LBot, ande 1 metro para a esquerda, gire 45 graus para a direita, depois ande 50 para trás"), o modelo deve mapear essa intenção para a sintaxe rigorosa da LBML (e.g., D100L;R45R;D50B;). O Semantic Parsing para LBML, portanto, não apenas executa uma tarefa, mas garante que o comando gerado seja sintaticamente correto e fisicamente seguro para o robô, um fator crítico em aplicações de robótica.

2.2. Arquiteturas de Modelos e Mecanismos de Atenção

O avanço na precisão do Semantic Parsing está intrinsecamente ligado à evolução das arquiteturas de modelos, especialmente os Transformers (Wang et al. 2021; Banerji et al. 2025). O trabalho de Banerji et al. (Banerji et al. 2025) propôs um framework unificado baseado em um mecanismo de autoatenção com consciência de relações (relation-aware self-attention). Essa técnica representa o esquema como um grafo, onde as arestas codificam relações explícitas (e.g., chave primária), permitindo que o modelo incorpore a estrutura relacional do domínio na sua representação interna.

Essa necessidade de vincular elementos da linguagem natural à estrutura formal se aplica diretamente ao LBot: embora o domínio não seja um banco de dados, o robô opera

em um espaço físico com estados e parâmetros. A correta "ligação" (linking) entre substantivos e verbos em português (e.g., "esquerda" ou "virar") e os parâmetros numéricos corretos na LBML é análoga ao Schema Linking tradicional. Portanto, modelos baseados em mecanismos de atenção são ideais para codificar essa estrutura de domínio, mesmo que simplificada para a topologia do robô.

2.3. Técnicas de Treinamento e Adaptação de Domínio

A adaptação de modelos de linguagem para domínios específicos é um tema recorrente. As abordagens mais comuns incluem o uso de Large Language Models (LLMs) pré-treinados, seguidos por Fine-Tuning (Ajuste Fino) ou In-Context Learning (ICL). Alternativamente, alguns trabalhos optam por treinar modelos do zero, permitindo maior controle sobre a arquitetura e o comportamento do modelo, embora isso demande mais recursos computacionais e dados de treinamento.

2.3.1. Fine-Tuning e ICL

O Fine-Tuning de LLMs (como o proposto no trabalho de NL2SQL para painéis de IoT (Banerji et al. 2025)) envolve o uso de um conjunto de dados específico do domínio (e.g., dados de IoT) para adaptar um modelo pré-treinado (e.g., GPT-2) para uma tarefa especializada. Essa abordagem é eficiente em recursos, pois aproveita a base de conhecimento do pré-treinamento. O In-Context Learning (ICL), por sua vez, permite que o modelo aprenda a tarefa apenas por meio de exemplos fornecidos no prompt de entrada, sem a necessidade de atualizar os pesos do modelo (Wu et al. 2025).

2.3.2. A Escolha do Treinamento do Zero e o Controle da Saída

Embora a maioria dos trabalhos recentes utilize LLMs pré-treinados, algumas abordagens optam por treinar modelos do zero. O RAT-SQL (Wang et al. 2021), por exemplo, treinou um modelo baseado em relation-aware self-attention especificamente para a tarefa de NL-to-SQL, alcançando resultados competitivos ao capturar as relações estruturais do esquema de banco de dados desde o início do treinamento.

Este trabalho adota uma estratégia semelhante ao optar por treinar um modelo pequeno do zero em um conjunto de dados exclusivo (Português-para-LBML). Esta escolha permite:

1. **Evitar dependência de LLMs pré-treinados;**
2. **Garantir controle total sobre o vocabulário e as regras da LBML.**

2.3.3. Garantia de Estrutura e Sintaxe

Para garantir que a saída gerada seja sempre um comando LBML sintaticamente válido, o controle da estrutura da DSL é essencial. O conceito de Grammar Prompting (Wang et al. 2023) utiliza métricas como a Taxa de Correspondência Exata (Exact Match Rate) em datasets desafiadores como o SPIDER. De forma semelhante, o trabalho de estratégias financeiras (Wu et al. 2025) prioriza esta métrica, por ser a única que garante que

o comando gerado é 100% correto. A aplicação dessa métrica é essencial para o LBot, uma vez que, em robótica, qualquer erro na sintaxe da LBML pode resultar em falha de execução ou em um movimento perigoso.

3. Desenvolvimento da Proposta de Solução

Esta seção apresenta o planejamento do desenvolvimento do sistema proposto para tradução de comandos em linguagem natural para a LBot Movement Language (LBML). A proposta está organizada em etapas sucessivas, iniciando pela geração do conjunto de dados sintético, seguida da implementação de um modelo base de tradução utilizando arquitetura Transformer, e, posteriormente, do aprimoramento deste modelo com a incorporação do mecanismo de atenção sensível a relações (*Relation-Aware Self-Attention*, RASA). Por fim, será conduzida uma comparação entre as duas versões, de modo a avaliar o impacto da atenção relacional no desempenho do tradutor.

3.1. Geração do Conjunto de Dados Sintético

A primeira etapa do projeto consiste na criação de um conjunto de dados sintético para o treinamento inicial do modelo. Pretende-se gerar automaticamente pares de exemplos no formato *Português* → *LBML*, utilizando um script capaz de combinar diferentes padrões de instruções. Cada amostra representará um comando em linguagem natural e sua respectiva tradução na sintaxe padronizada da LBML.

O dataset abrangerá tanto instruções simples quanto compostas, permitindo ao modelo aprender a estrutura sequencial dos comandos. Serão incluídas variações linguísticas e sinônimos (por exemplo, “ande”, “mova-se”, “siga”) e ruído leve, como variações de acentuação ou ordem dos termos, de modo a aumentar a robustez do modelo diante de entradas reais. Os valores de distância e rotação serão representados em centímetros e graus, respeitando o formato definido pela LBML.

3.2. Modelo Base sem Relações Explícitas

A segunda etapa prevê o desenvolvimento de um modelo de tradução baseado na arquitetura Transformer, sem a inclusão inicial de mecanismos de atenção relacional. O modelo foi implementado utilizando uma arquitetura do tipo *Transformer decoder-only*, inspirada em modelos da família GPT. A configuração definida para este trabalho consiste em seis camadas (*layers*), seis cabeças de atenção e vetores de representação de 384 dimensões. O tamanho máximo do contexto foi fixado em 128 tokens, valor adequado para representar comandos contendo até três ações encadeadas.

O vocabulário definido para o modelo possui 70 caracteres, contemplando letras, números, pontuação e os símbolos específicos da LBML. O valor de *dropout* adotado é 0,2, buscando garantir estabilidade durante o treinamento sobre um conjunto de aproximadamente 40 mil exemplos sintéticos. Essa configuração foi planejada para oferecer um bom equilíbrio entre capacidade de aprendizado, custo computacional e adequação à complexidade da tarefa de tradução.

O processo de treinamento será acompanhado por avaliações periódicas, utilizando métricas como *Exact Match Rate* e *BLEU Score*, que permitirão monitorar a evolução do modelo e sua capacidade de gerar comandos sintaticamente válidos.

3.3. Aprimoramento com Atenção Relacional (RASA)

Nesta etapa, será criada uma segunda versão do modelo adicionando um novo tipo de atenção chamado *Relation-Aware Self-Attention* (RASA). O objetivo dessa camada é ajudar o modelo a ligar diretamente palavras do português aos símbolos correspondentes da LBML.

Enquanto o modelo base possui apenas a atenção causal seguida da MLP, o modelo com RASA acrescenta uma segunda atenção dentro de cada bloco Transformer. Assim, cada bloco passa a ter três etapas: atenção causal, atenção relacional e MLP, cada uma com uma conexão residual.

A atenção relacional funciona adicionando informações extras sobre quais tokens costumam estar relacionados. Para isso, o modelo utiliza uma matriz aprendível que representa relações entre todos os tokens do vocabulário. Essa matriz é incorporada no cálculo da atenção, fazendo com que pares de tokens relacionados recebam maior peso. Exemplos típicos incluem associações como “frente” com “F”, “trás” com “B” e “esquerda” com “L”.

Outra diferença importante é que a atenção relacional leva em conta diretamente os identificadores dos tokens da entrada, o que permite que o modelo aprenda essas relações de forma explícita. Com isso, o modelo passa a gerar comandos LBML mais consistentes, especialmente em instruções compostas ou com múltiplas ações.

Em resumo, o RASA acrescenta ao modelo a capacidade de reconhecer relações semânticas específicas da tarefa, melhorando o alinhamento entre linguagem natural e a LBML.

3.4. Comparação entre as Versões

A etapa final do desenvolvimento consistirá na comparação entre o modelo base e o modelo aprimorado com RASA. Ambos serão treinados com o mesmo conjunto de dados e parâmetros idênticos, de modo que as diferenças observadas no desempenho possam ser atribuídas exclusivamente à introdução da atenção relacional.

A métrica de avaliação será a *Exact Match Rate*. Serão analisadas separadamente instruções simples e compostas, a fim de verificar se o ganho de desempenho é mais significativo em cenários com maior complexidade sintática.

4. Análise de Resultados

Esta seção apresenta a avaliação comparativa entre o modelo base (LBot V5) e a versão aprimorada com o mecanismo *Relation-Aware Self-Attention* (LBot V5.1). Ambos os modelos foram treinados sob as mesmas condições, utilizando o mesmo conjunto de dados sintético e a mesma configuração de hiperparâmetros, permitindo que os efeitos do RASA fossem isolados de outras variáveis do treinamento.

4.1. Acurácia Global

A métrica utilizada para avaliar o desempenho dos modelos foi a *Exact Match Rate*, por ser a única capaz de garantir que o comando gerado é sintaticamente e semanticamente idêntico ao esperado, requisito fundamental em aplicações robóticas.

A Figura 1 apresenta a comparação direta entre as duas versões. Observa-se que o modelo com RASA obteve um ganho de **+1,46%** na acurácia geral. Embora aparentemente moderado, esse incremento é consistente e revela que a atenção relacional contribui para um alinhamento mais preciso entre expressões em português e seus correspondentes na LBML.




Figure 1. Comparação da acurácia geral entre o modelo base (V5) e o modelo com RASA (V5.1).

4.2. Desempenho por Tipo de Comando

Os resultados foram analisados separadamente entre três categorias: instruções simples, instruções compostas em duas ações e instruções compostas em três ações. A Figura 2 resume os ganhos obtidos.

As principais conclusões são:

- **Instruções simples:** ganho de **+2,27%**, indicando melhor ligação entre direções e deslocamentos curtos.
- **Instruções compostas com três ações:** ganho expressivo de **+5%**, sendo esta a categoria onde o modelo base apresentava maior dificuldade.
- **Instruções com rotações:** ambos os modelos alcançaram **100%** de acurácia, sugerindo que rotações são padrões mais fáceis de aprender no domínio.
- **Instruções compostas com duas ações:** desempenho idêntico entre os modelos.

Esses resultados demonstram que o RASA melhora sobretudo a capacidade do modelo de lidar com dependências de longo alcance e com a combinação sequencial de ações, dificuldades típicas da tarefa de parsing semântico para DSLs.

4.3. Custo Computacional

A introdução da camada de atenção relacional traz melhorias de desempenho, mas também impõe custos adicionais. A Figura 3 resume esses impactos.

Os principais trade-offs observados foram:




Figure 2. Ganho de acurácia do modelo com RASA por tipo de instrução.

- **Aumento de 33% no tamanho do modelo**, devido à nova matriz aprendível de relações.
- **Aumento de 38% no tempo de inferência**, consequência do cálculo adicional da segunda atenção por bloco.

Embora esses custos possam ser considerados elevados para aplicações embarcadas, eles permanecem aceitáveis neste cenário experimental, em que o objetivo principal é avaliar a viabilidade do mecanismo relacional.




Figure 3. Impacto do RASA no custo computacional do modelo.

Em síntese, o RASA melhora a qualidade da tradução especialmente em comandos mais complexos, ao custo de maior tempo de processamento e maior consumo de memória. Essa relação custo–benefício deve ser considerada em implementações práticas do LBot.

5. Conclusão

Este trabalho investigou a tradução de comandos em linguagem natural para a LBot Movement Language (LBML) por meio de modelos baseados em Transformers, avaliando uma arquitetura padrão e uma versão aprimorada com o mecanismo *Relation-Aware Self-Attention* (RASA). Os experimentos demonstraram que, embora o RASA tenha proporcionado melhorias consistentes na acurácia, especialmente em comandos compostos mais

complexos, nenhum dos modelos se mostrou suficientemente confiável para aplicação prática sem supervisão humana.

Os resultados indicam que a tarefa apresenta desafios que vão além da simples ampliação do mecanismo de atenção, sugerindo limitações tanto do conjunto de dados sintético mecanismo de atenc, ~ ao sen quanto da arquitetura adotada. Em particular, a dificuldade em generalizar para instruções que divergem dos padrões presentes no dataset evidencia a necessidade de uma reformulação mais profunda do processo de coleta de dados, incorporando maior diversidade linguística e mais exemplos de instruções reais de usuários.

Apesar dessas restrições, conclui-se que a atenção relacional representa uma alternativa viável para melhorar o desempenho sem aumentar a profundidade da rede ou alterar o dataset. O RASA demonstrou capacidade de reforçar as ligações entre tokens do português e seus correspondentes na LBML, tornando o modelo mais robusto para comandos longos e sequenciais. No entanto, essa técnica não deve ser tratada como uma solução definitiva, pois implica aumento significativo no custo computacional.

Dessa forma, considera-se que o RASA foi uma adição válida dentro do escopo deste trabalho, mas que avanços mais expressivos exigirão revisões no dataset, na arquitetura e possivelmente na própria definição da DSL. Tais melhorias são essenciais para aproximar o sistema de um nível de confiabilidade adequado para uso em cenários reais de interação com robôs.

References

- [Banerji et al. 2025] Banerji, J., Amin, A., and Rathor, K. (2025). Llm driven natural language to sql for utility dashboards. *IEEE International Students' Conference on Electrical, Electronics, and Computer Science*, pages 1–6.
- [Sharma et al. 2025] Sharma, A. K., Kanumuri, S. C., A R, P., and Sharath, S. S. (2025). Advancing natural language to sql: A comparative study of open source llms on benchmark datasets. *Natural Language Processing and Information Retrieval*.
- [Wang et al. 2021] Wang, B., Shin, R., Liu, X., Polozov, O., and Richardson, M. (2021). Rat-sql: Relation-aware schema encoding and linking for text-to-sql parsers. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics*, pages 7567–7578.
- [Wang et al. 2023] Wang, L., Xu, W., Lan, Y., Hu, Z., Lan, Y., Lee, R. K.-W., and Lim, E.-P. (2023). Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, pages 2609–2634.
- [Wu et al. 2025] Wu, J., Zhang, D., and Niu, Q. (2025). Formulating financial trading strategies using llm: A dsl-mediated approach via in-context learning. *Proceedings of the 7th International Conference on Natural Language Processing*, pages 123–135.