



Projeto LBot

Mestrado em Computação Aplicada - UDESC
Aluno: Guilherme Mendes Rosa

Motivação

- Unir robótica e inteligência artificial
- Robôs normalmente exigem comandos técnicos ou linguagem específica
- Usuários comuns normalmente não conseguem utilizar
- Inteligência artificial pode nos auxiliar com isso



Objetivo do Trabalho

Criar uma interface que consiga executar comandos no robô por meio de linguagem natural:

- Criar uma linguagem específica de domínio (DSL) → LBML
- Criar um modelo baseado em aprendizado supervisionado com arquitetura Transformer que converta linguagem natural para LBML (nl2lbml)



Conceitos Fundamentais

- DSL (Linguagem de Domínio Específico): Reduz ambiguidade e aumenta segurança
- Semantic Parsing: Traduz linguagem natural para comandos formais
- Transformers: Arquitetura base para tradução e modelagem de sequência
- RASA: Atenção que incorpora relações explícitas entre tokens

Linguagens de Domínio Específico (DSL)

- DSLs reduzem ambiguidades da linguagem natural.
- Restrição de vocabulário → maior precisão e segurança.

Ande 50cm pra direita, gire 90 graus para a esquerda	D50R;R90L;
Volte 30cm	D30B;

Semantic Parsing

- Tradução de frases em linguagem natural para representações formais executáveis.
- Aplicações comuns: consultas NL-to-SQL, geração de código, robótica.
- Base para sistemas que precisam interpretar e executar instruções.

Arquiteturas Baseadas em Transformers

- Entende e gera textos, analisando todas as palavras de uma frase ao mesmo tempo.
- Em vez de ler palavra por palavra em sequência, o Transformer olha para todos os pedaços do texto ao mesmo tempo e descobre quais partes são mais importantes para entender o sentido.
- Permite que a IA entenda contexto, significado e relações de maneira muito mais rápida e precisa do que modelos antigos.

Relation-Aware Self-Attention

- Adiciona uma segunda atenção dentro de cada bloco
- Criando basicamente uma ligação de grafos por arestas
- Facilita mapear:
 - “frente” $\leftrightarrow$ F
 - “esquerda” $\leftrightarrow$ B
 - “direita” $\leftrightarrow$ R
 - “voltar” $\leftrightarrow$ B
- Ajuda especialmente em instruções longas/compostas

Proposta de Solução


Pontos principais:

- Sistema de tradução de comandos em português → LBML.
- Baseado em aprendizado supervisionado com arquitetura Transformer.
- Estrutura em 4 etapas: Dataset, Modelo Base, RASA e Comparação.




Transformer (modelo base)

- Arquitetura utilizada: decoder-only (tipo GPT)
- 6 camadas, 6 cabeças de atenção, 384 dimensões
- Tamanho do contexto: 128 tokens
- Treinado do zero com ~40.000 exemplos sintéticos



Resultados: Acurácia Global


- Ganho geral com RASA: +1,46%
- Melhor alinhamento LN → LBML
- Melhoria especialmente em comandos longos



Resultados por Tipo de Comando

- Simples: +2,27%
- 3 ações: +5%
- Rotações: ambos com 100%
- 2 ações: desempenho igual


Conclusão: O RASA ajuda quando há dependências mais longas ou múltiplas etapas



Custo Computacional

- +33% de parâmetros
- +38% de tempo de inferência
- Trade-off entre precisão e custo

Custo Computacional do RASA



Conclusões

- RASA melhora a qualidade da tradução, especialmente em comandos compostos
- Mas não consegue proporcionar uma melhoria realmente considerável
- Resultado não o suficiente para uso real sem supervisão
- Próximos passos:
 - melhorar o dataset
 - alterar a parametrização
 - arquiteturas maiores