

Revisão de Conceitos e Trabalhos Relacionados – Projeto LBot

Mestrado em Computação Aplicada - UDESC
Aluno: Guilherme Mendes Rosa

Panorama dos Trabalhos Relacionados

1. Advancing Natural Language to SQL: A Comparative Study of Open Source LLMs on Benchmark Datasets - Sharma (2025):
Revisão sobre Semantic Parsing e aplicações NL-to-SQL/DSL.
2. Formulating Financial Trading Strategies using LLM: A DSL-Mediated Approach via In-Context Learning - Wu (2025):
DSL como intermediário para reduzir erros e alucinações de LLMs.
3. LLM driven Natural Language to SQL for Utility Dashboards - Banerji (2025)
Relation-aware self-attention para incorporar estrutura do domínio.
4. RAT-SQL: Relation-Aware Schema Encoding and Linking for Text-to-SQL Parsers - Wang (2019)
Uso de Transformers no parsing para capturar relações complexas.
5. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models - Wang (2023)
Grammar Prompting para garantir saídas sintaticamente corretas.

 Relação: todos fundamentam o uso da LBML como camada intermediária para traduzir linguagem natural em comandos seguros ao LBot.

O que é Semantic Parsing?

- Tradução de frases em linguagem natural para representações formais executáveis.
- Aplicações comuns: consultas NL-to-SQL, geração de código, robótica.
- DSL criada: LBot Movement Language (LBML) para descrever movimentos de forma padronizada.
- Base para sistemas que precisam interpretar e executar instruções humanas.

 Sharma (2025): destaca o papel central do Semantic Parsing na interação humano-máquina.

Linguagens de Domínio Específico (DSL)

- DSLs reduzem ambiguidades da linguagem natural.
- Restrição de vocabulário → maior precisão e segurança.
- Exemplo no LBot: LBML (D100L; = mover 100 cm para esquerda).

 Wu (2025): mostra que $LN \rightarrow DSL \rightarrow \text{Execução}$ reduz falhas em comparação ao mapeamento direto $LN \rightarrow \text{Código}$.

Arquiteturas Baseadas em Transformers

- **O que são Transformers?**
 - Modelos que usam mecanismos de atenção para identificar quais partes de uma frase são mais relevantes entre si.
- **Por que são importantes no Semantic Parsing?**
 - Permitem lidar com frases longas e complexas.
 - Capturam relações entre palavras distantes (“ande para a esquerda 2 metros” → conecta verbo ande com distância 2 metros e direção esquerda).
-  **Wang (2019): mostrou que Transformers superam modelos anteriores ao traduzir linguagem natural em consultas SQL.**

 Relação com o LBot: atenção ajuda a mapear corretamente ação + direção + distância para LBML.

Relation-Aware Self-Attention

- Relation-Aware Self-attention adiciona arestas de um grafo ao mecanismo de atenção.
 - Em SQL: liga colunas a tabelas (ex.: cliente.nome → tabela cliente).
 - Em robótica: liga comando verbal a parâmetro físico (ex.: “virar” → rotação, “andar” → deslocamento).
-  Banerji (2025): framework que insere relações estruturais no modelo, aumentando a precisão.

Grammar Prompting

- Desafio: modelos podem gerar saídas inválidas (comando incompleto ou incorreto).
- O que é Grammar Prompting?
 - Técnica que força o modelo a seguir regras gramaticais da linguagem-alvo.
 - Funciona como um “guia” que limita o espaço de saída do modelo.
- Métrica chave: Exact Match Rate → mede se a saída é exatamente igual ao esperado.
- 📖 Wang (2023): usado no dataset SPIDER, garante saídas sintaticamente corretas.

🔗 Relação com o LBot: evita que o robô receba comandos inválidos (ex.: D10X; → inválido, D100L; → válido).

Técnicas de Treinamento

- Fine-Tuning: adapta modelos grandes a domínios específicos.
- In-Context Learning (ICL): aprendizado via exemplos no prompt.
- Treinamento do zero: cria modelo pequeno, especializado e totalmente controlado.
- 📖 Wu (2025) e Banerji (2025): exploram FT/ICL em domínios específicos.

Decisão do Projeto (Treinar do Zero)

- Reduz dependência de LLMs gigantes.
- Garante que o modelo só aprenda a estrutura da LBML.
- Evita “ruído” de conhecimento externo que não pertence ao domínio.
- Maior controle sobre segurança na execução dos comandos.

Síntese e Conclusões

- Semantic Parsing (Sharma, 2025) é a base do campo.
- DSLs aumentam precisão e segurança (Wu, 2025).
- Transformers impulsionaram avanços na área (Wang, 2021).
- Relation-aware self-attention melhora o mapeamento (Banerji, 2025).
- Grammar Prompting garante comandos válidos (Wang, 2023).